
Acumulación de Capital Humano y Crecimiento Económico en el Siglo XXI

Inteligencia Artificial, Calidad Educativa y Asignación de Talento

Gabriela N. Villalba Marecos

Candidata a Doctora en Economía · Universidad de Sussex

Seminario de Crecimiento Económico · 20 de junio de 2025 · Modalidad Virtual

Gabriela Noemi Villalba Marecos es economista egresada de la Universidad Nacional de Asunción con honores y Magíster en Development Economics con Distinction por la Universidad de Sussex, donde actualmente cursa el Doctorado en Economía.

Su investigación se centra en la **economía de la educación**, el **capital humano** y el **desarrollo económico** en América Latina, con énfasis en calidad de la educación superior, acreditación universitaria, *educational mismatch* y desigualdades educativas en Paraguay y Colombia.

Ha trabajado como asistente de investigación en la LSE y en la Universidad de Sussex, donde también se desempeña como Doctoral Tutor en el Departamento de Economía.

Su trabajo ha sido presentado en la *Royal Economic Society Annual Conference 2026*, la *5th Annual Southern PhD Economics Conference* y el *Junior Workshop on Economics of Latin America* (Freie Universität Berlin / LAI, julio 2026).

g.n.villalba-marecos@sussex.ac.uk · University of Sussex, Department of Economics

Horario	Actividad
09:30 – 09:40	Bienvenida e introducción
09:40 – 10:40	Parte I. Capital humano, IA y crecimiento económico
10:40 – 10:50	<i>Pausa</i>
10:50 – 11:50	Parte II. Calidad educativa y asignación de talento
11:50 – 12:00	<i>Pausa</i>
12:00 – 12:30	Parte III. Estudiar en el exterior como inversión
12:30 – 12:45	Preguntas, discusión y cierre

PARTE I

Capital Humano y Crecimiento Económico en el Siglo XXI

¿Por qué el capital humano sigue siendo uno de los motores
más importantes del crecimiento económico?

Temas centrales

- Capital humano como factor de crecimiento
- Productividad, conocimiento e innovación
- Transición hacia economías basadas en conocimiento
- Habilidades y crecimiento económico
- Nuevos desafíos para la acumulación de capital humano

Pregunta central

¿Por qué el capital humano sigue siendo uno de los motores más importantes del crecimiento económico?

Las economías modernas dependen cada vez más del **conocimiento**, las **habilidades** y la **capacidad de innovar** como fuentes de ventaja comparativa.

La visión optimista

- La IA como **tecnología de uso general** (GPT): reduce costos, expande posibilidades productivas (Bresnahan, 2021)
- Complementa el capital humano existente y genera **nuevas tareas** (Acemoglu & Restrepo, 2019)
- Evidencia: IA generativa aumenta productividad de trabajadores de soporte al cliente (Brynjolfsson et al., 2023)

La visión pesimista

- La IA puede automatizar **tareas cognitivas** antes consideradas seguras (Acemoglu, 2022)
- Si la innovación va hacia la sustitución de trabajo (no complementariedad), el crecimiento no se traduce en bienestar (Acemoglu & Johnson, 2023)
- Riesgo de **cambio tecnológico sesgado**: amplía desigualdad salarial

El vínculo con la acumulación de capital humano

Romer (1990) y Lucas (1988) pusieron el conocimiento y el capital humano en el centro del crecimiento. La IA redefine **qué tipo** de capital humano importa: no más años de escolaridad en abstracto, sino *qué habilidades* acumula la fuerza de trabajo.

Una literatura que creció rápido — y aún tiene más preguntas que respuestas

Estudio	Hallazgo principal
Acemoglu et al. (2022)	Empresas con tareas aptas para IA aumentan vacantes de IA y <i>reducen</i> contratación general
Brynjolfsson et al. (2023)	IA generativa ↑ productividad de agentes de soporte (+14 %)
Hui, Reshef & Zhou (2023)	IA generativa reduce empleo de freelancers en plataformas online
Albanesi et al. (2023)	Ocupaciones expuestas a IA en Europa: evidencia mixta, sin efecto neto claro
Bonfiglioli et al. (2024)	Efecto neto negativo sobre empleo en zonas de commuting de EEUU (2SLS)

La pregunta que organiza la Parte I

La mayoría de los estudios miden *exposición* a la IA. Bonfiglioli et al. (2024) son los primeros en estimar el efecto causal de la **adopción** de IA sobre el empleo total, con variación geográfica y estrategia de identificación rigurosa.

Preguntas clave

- ¿Automatización vs. complementariedad?
- Cambio tecnológico **sesgado por habilidades**
- ¿Qué habilidades serán más valiosas en el futuro?

Artículo de referencia

Bonfiglioli, Crinò, Gancia & Papadakis (2024)

Pregunta de cierre — Parte I

Si la tecnología cambia el valor de las habilidades, ¿cómo desarrollamos el capital humano necesario para el crecimiento futuro?

¿Qué puede hacer la IA con el empleo?

Dos efectos posibles

- 1 **Automatización (desplazamiento):** la IA reemplaza tareas antes realizadas por personas
- 2 **Complementariedad (productividad):** la IA potencia la capacidad de los trabajadores y expande la producción

El efecto **neto** sobre el empleo es una pregunta empírica, no teórica.

El modelo de Bonfiglioli et al.

Cada industria produce combinando **tareas**: algunas las realiza la IA, otras los trabajadores.

Si la IA asume más tareas $\Rightarrow$ doble efecto:

- $\downarrow$ demanda laboral directa
- $\uparrow$ producción total $\Rightarrow \uparrow$ demanda laboral indirecta

El signo final depende de cuál domina.

El desafío

No existe una estadística oficial de “uso de IA por empresa”. Los autores construyen una medida nueva.

Ocupaciones relacionadas con IA

Usando la base O*NET (EEUU), identifican **19 ocupaciones** cuyos avisos laborales requieren software especializado de machine learning y análisis de datos (Python, SQL, Apache Spark, etc.)

Ejemplos: *Data Scientist, Software Developer, Statistician, Database Architect*

La medida de adopción

Para cada zona de commuting c y década t :

$$Alado_{ct} = \frac{L_{c,t_1}^{AI} - L_{c,t_0}^{AI}}{L_{c,2000}}$$

Cambio en el **peso relativo** de empleos ligados a IA respecto al empleo total inicial.

Unidad de análisis: 722 *commuting zones* (mercados laborales locales) de EEUU, 2000–2020.

¿Por qué no basta con OLS?

Un shock de demanda local puede *simultáneamente* aumentar el empleo y la adopción de IA $\Rightarrow$ correlación espuria positiva. El OLS estaría sesgado hacia arriba.

Solución: Instrumento *shift-share* (Bartik)

$$Aexp_{ct} = \sum_i \underbrace{\lambda_{ci,1980}}_{\text{composición industrial histórica}} \times \underbrace{\left(\frac{L_{i,t_1}^{AI} - L_{i,t_0}^{AI}}{L_{i,2000}} \right)}_{\text{adopción nacional por industria}}$$

- Las **shares** son de 1980 (antes de existir la IA) $\Rightarrow$ exógenas
- Los **shifts** son nacionales $\Rightarrow$ no dependen del mercado local
- Zonas especializadas en industrias con mayor adopción de IA $\Rightarrow$ mayor exposición

Hallazgo principal (2SLS)

Un aumento de 1 desviación estándar en la adopción de IA reduce la tasa empleo/población en **1 punto porcentual**.

⇒ El efecto de **automatización domina** al de productividad.

¿Por dónde opera?

- Principalmente en **servicios** (no manufactura)
- Diferente a los robots industriales

Heterogeneidad: ¿quién pierde y quién gana?

Pierden:

- Trabajadores de **baja calificación**
- Trabajadores de producción
- Quintiles **1 a 4** de la distribución salarial

Ganan:

- Trabajadores **STEM** calificados
- Quintil **5** (top 10 % salarial)

¿Qué nos dice esto para el crecimiento?

- La IA no es simplemente “mala” o “buena” para el empleo: **redistribuye** quién trabaja y en qué
- El sector servicios — corazón de los países desarrollados — no está protegido de la automatización
- La educación STEM y las habilidades técnicas avanzadas son **complementos** de la IA, no sustitutos

Pregunta de discusión

Si la IA beneficia principalmente al 10 % superior de la distribución salarial, ¿qué tipo de inversión en **capital humano** necesitan los países de América Latina para que sus trabajadores no queden del lado perdedor?

PARTE II

Desigualdades Educativas y Asignación de Talento

¿Se está desarrollando y utilizando eficientemente el talento disponible?

El contexto

- Paraguay ha mejorado en acceso: 90 % completa la educación básica, analfabetismo bajó del 9,6 % al 5,5 %
- Pero **acceso** $\neq$ **calidad**: las brechas de aprendizaje persisten y se amplifican
- País oficialmente bilingüe (español/guaraní), con mercado laboral formal casi exclusivamente en castellano

Vacío en la literatura

Existían estudios descriptivos, pero **ningún análisis econométrico** con los microdatos censales del SNEPE.

Lovera & Villalba (2025) llenan ese vacío: primer análisis nacional con datos del SNEPE 2018 (3er año de Educación Media).

Datos: SNEPE 2018

- Evaluación **censal** (no muestral): todos los estudiantes de 3er año de Media
- $N \approx 31,500$ estudiantes
- Puntajes en **castellano y matemáticas** estandarizados (z-scores)
- Variables individuales: nivel socioeconómico (NS), idioma del hogar, repitencia, trabajo, sexo
- Variables institucionales: zona, gestión escolar, infraestructura, TIC

Dos herramientas econométricas

1. OLS con interacciones:

$$z_{is} = \beta_0 + \beta_1 P_s + \beta_2 NS_i + \beta_3 (P_s \times NS_i) + \theta X_i + \lambda Z_s + \delta_d + \varepsilon_{is}$$

Identifica si el gradiente socioeconómico varía según tipo de gestión.

2. Descomposición Oaxaca-Blinder:

Separa la brecha pública-privada en **dotaciones** (quiénes asisten) vs. **retornos** (cómo la escuela convierte esas dotaciones en aprendizaje).

Prueba	Comparación	Diferencia (DE)	d Cohen	p
Castellano	Privada – Pública	0,49	0,49	<0,001
Matemática	Privada – Pública	0,41	0,41	<0,001
Castellano	Urbana – Rural	0,33	0,33	<0,001
Matemática	Urbana – Rural	0,08	0,08	<0,001

Hallazgo clave

Las brechas por **gestión escolar** son sustancialmente mayores que las geográficas. Y son más marcadas en **castellano** que en matemáticas.

Referencia

Cohen's $d = 0,49$ equivale a un efecto **mediano-alto**. Para ponerlo en perspectiva: en una prueba con $DE = 100$ puntos, eso son 49 puntos de diferencia promedio.

Castellano (M3 con interacción)

- Escuela privada: +0,21 DE***
- NS × Privada: +0,32 DE***
- NS × Pública: +0,12 DE***
- Ser mujer: +0,08 DE***
- Repetir curso: -0,37 DE***
- Guaraní en hogar: -0,11 DE***
- Trabajar fuera: -0,15 DE***

El hallazgo de la interacción

El gradiente socioeconómico se amplifica en el sector privado.

En escuelas públicas: pasar del NS más bajo al más alto $\Rightarrow$ +0,7 DE en castellano.

En escuelas privadas: el mismo cambio $\Rightarrow$ +2,0 DE.

$\Rightarrow$ Las escuelas privadas **amplifican** las desventajas de origen; las públicas las **amortiguan** (pero no las eliminan).

Componente	Castellano		Matemáticas	
	Coef.	%	Coef.	%
Dotaciones	−0,34	61 %	−0,36	76 %
Retornos	−0,32	58 %	−0,37	79 %
Interacción	+0,11	−19 %	+0,26	−55 %
Brecha total	−0,55	100 %	−0,47	100 %

¿Qué son las dotaciones?

Diferencias en *quiénes* van a cada tipo de escuela: nivel socioeconómico, idioma del hogar, repitencia. Si los estudiantes privados y públicos fueran idénticos, parte de la brecha desaparecería.

¿Qué son los retornos?

Diferencias en *cómo* cada tipo de escuela convierte los recursos disponibles en aprendizaje. Incluso con estudiantes idénticos, las escuelas privadas generan resultados más altos — **segmentación estructural**.

La pregunta del working paper

¿Qué escuelas logran *más aprendizaje del esperado* dado su contexto? El valor agregado (VA) aísla la contribución neta de la escuela, eliminando el efecto del origen socioeconómico de los estudiantes.

$$VA_{it} = \varepsilon_{it} \text{ (residuo del modelo ajustado)}$$

Lo que aprendemos

- NS sigue siendo el predictor más fuerte (+0,39 DE en Castellano)
- Privadas mantienen VA superior al promedio nacional
- Índice de Theil: 0,19 (Castellano) y 0,22 (Matemáticas) $\Rightarrow$ desigualdad territorial persistente

El aporte metodológico — y sus límites

Lo que permite: identificar escuelas efectivas en contextos adversos; una evaluación más justa que los rankings brutos.

Las limitaciones (y qué nos enseñan sobre hacer research en países en desarrollo):

- Solo 2 años de datos $\rightarrow$ poca variación temporal
- Sin identificadores individuales $\rightarrow$ no panel de estudiantes
- Variables de autonomía e infraestructura casi no cambian entre 2015 y 2018

$\Rightarrow$ Los datos disponibles **limitan** qué preguntas causales podemos responder.

Lo que Paraguay nos enseña sobre investigación en economía de la educación

- Los microdatos censales son valiosos aunque no sean panel: permiten descripción rigurosa y análisis de brechas
- Sin reforma o variación exógena, la identificación causal es difícil — pero la **pregunta sigue siendo importante**
- La descomposición Oaxaca-Blinder es una herramienta poderosa para diagnosticar *de dónde viene* una brecha, incluso sin causalidad
- El valor agregado es más justo que un ranking bruto, pero requiere datos longitudinales para ser robusto

Pregunta de discusión

Si el 61 % de la brecha pública-privada se debe a *quiénes* asisten a cada tipo de escuela, ¿qué política tendría mayor impacto: mejorar la calidad de las escuelas públicas, o reducir la segregación socioeconómica de entrada?

El problema de asignación

En educación superior, **no solo importa si vas a la universidad** — importa *a cuál*.

Mismatch: un estudiante no termina en la institución de mayor calidad a la que podría acceder dada su habilidad.

Causas posibles: restricciones financieras, barreras geográficas, información imperfecta, redes sociales.

¿Por qué Colombia?

- Sistema **descentralizado**: cada universidad define sus propios criterios de admisión
- Sin plataforma común de postulación $\Rightarrow$ costos de información caen sobre quienes menos los pueden pagar
- Acceso a crédito (ICETEX) limitado: solo el 9,5 % de la muestra accedió a Ser Pilo Paga
- Instituciones concentradas en grandes ciudades $\Rightarrow$ barrera geográfica real

Datos: ICFES administrativos vinculados

- **Saber 11** (entrada): puntaje estandarizado al final del secundario — mide habilidad pre-entrada
- **Saber Pro** (salida): examen al finalizar la carrera — mide resultados de aprendizaje
- Vinculados a nivel individual: 505.009 estudiantes, cohortes 2012–2015

Medida de calidad institucional

Leave-one-out peer composition: promedio del percentil Saber 11 de los compañeros de institución, excluyendo al propio estudiante.

$$Q_{h,-i} = \text{PercentileRank}\left(\frac{1}{N_h-1} \sum_{j \in h, j \neq i} A_j\right)$$

El mismatch continuo

$$M_i = Q_{h,-i} - A_i$$

- $M_i < 0$: **undermatch** (va a una institución por debajo de su nivel)
- $M_i > 0$: **overmatch**
- $M_i \approx 0$: asignación eficiente

Con umbral ± 15 percentiles:

27 % undermatched · 45 % matched · 27 % overmatched

Tres patrones del paper (Figuras 1–2)

- 1 El sistema **asigna positivamente**: mayor habilidad $\Rightarrow$ mayor calidad institucional en promedio. No es asignación aleatoria.
- 2 Pero casi todos los grupos están **por debajo de la línea de 45°**: el undermatch es generalizado.
- 3 La brecha por **NSE es enorme y persistente**: para igual decil de habilidad, los estudiantes de alto ingreso van a instituciones hasta 2 deciles más arriba que los de bajo ingreso.

La brecha condicional en habilidad

Entre estudiantes de habilidad media:

- Alto ingreso vs. bajo ingreso: **+19 percentiles** de calidad institucional
- Incluso entre los mejores estudiantes la brecha persiste: **+9 percentiles**

Género: las diferencias son pequeñas — el NSE domina.

El sistema colombiano **ordena** el talento, pero lo hace de forma **inequitativa**: el origen socioeconómico determina en qué institución terminas, incluso controlando por habilidad.

¿Por qué RIF?

OLS estima el efecto en el *promedio*. Pero el mismatch importa en toda la distribución — especialmente en las colas.

La **RIF** (Firpo, Fortin & Lemieux, 2009) estima cómo cambia el *cuantil incondicional* del mismatch ante cambios en las covariables.

Resultado de género (sorprendente)

Las mujeres están **más overmatched** en toda la distribución (+2 a +4 p.p.). Pero la magnitud es pequeña frente al NSE.

Resultados RIF por ingreso (ref. = bajo ingreso)

	Q10	Q50	Q90
Ingreso medio	−0,37	−0,15	+0,54***
Ingreso alto	+7,67***	+2,84***	+2,20***
Esc. privada	+1,61***	+0,99***	+1,56***
Zona urbana	−3,43***	−2,74***	−3,92***

alto ingreso es **enorme en la cola baja** (Q10): quienes más undermatcharían sin dinero son exactamente quienes más se benefician de tener recursos.

Conectando con el hilo del seminario

- El crecimiento depende de *cuánto* capital humano hay en la sociedad, pero también de *cómo se asigna* ese talento a las instituciones
- Si estudiantes de alta habilidad y bajo NSE terminan en instituciones de baja calidad por restricciones financieras o geográficas ⇒ **pérdida de eficiencia social**
- Y si esa asignación además **reproduce la desigualdad de origen** ⇒ problema distributivo adicional

Lo que distingue a Colombia

Sistema descentralizado + restricción de crédito + barrera geográfica = condiciones que **amplifican** el mismatch respecto a contextos de países avanzados.

Pregunta de discusión

Si 9 percentiles de brecha persisten incluso entre los mejores estudiantes, ¿qué parte de ese gap refleja preferencias vs. restricciones? ¿Y qué política lo cierra?

La función de producción del capital humano

Lucas (1988) modela el capital humano como:

$$\dot{h} = \delta h \cdot u$$

donde h es el stock de capital humano, u el tiempo dedicado a aprender, y δ la eficiencia del proceso de acumulación.

Estudiar en el exterior actúa sobre **los tres**: acceso a más conocimiento, tiempo de inmersión total, y mayor eficiencia del entorno (pares, docentes, infraestructura).

La ventaja del economista

Cualquier persona evalúa esta decisión intuitivamente. Pero los economistas ya tenemos un **marco formal** para hacerlo:

- Función de utilidad intertemporal
- Valor presente de retornos futuros
- Restricción presupuestaria y acceso a crédito
- Optimización bajo incertidumbre

⇒ No es intuición, es **microeconomía aplicada a vos mismo**.

Decisión óptima de invertir en educación (Becker, 1964)

Estudiar en el exterior conviene si el valor presente de los retornos supera el costo total:

$$\sum_{t=1}^T \frac{w_t^{\text{ext}} - w_t^{\text{local}}}{(1+r)^t} \geq C_{\text{matrícula}} + C_{\text{vida}} + C_{\text{oportunidad}}$$

Los costos

- **Directos:** matrícula, alojamiento, visa, traslado
- **Oportunidad:** salario o experiencia que dejás de ganar mientras estudiás
- **Psicológicos:** distancia, incertidumbre, adaptación — reales aunque no monetarios

Los retornos

- **Salariales:** diferencial de ingresos (Psacharopoulos, 2018)
- **Redes:** contactos académicos y profesionales internacionales
- **Señalización:** credencial extranjera como proxy de calidad ante empleadores
- **Opcionales:** puertas que se abren y no se podían anticipar

Maestría en Development Economics — Sussex

- **Beca parcial** de la universidad (cubre parte de matrícula)
- **Préstamo AFD** (Agencia Financiera de Desarrollo, Paraguay)
- **Apoyo familiar** — componente real e indispensable, pero no siempre fácil de sostener

Desde el modelo: C no era cero. La inversión era viable porque los tres componentes se combinaron — ninguno solo alcanzaba.

Doctorado en Economía — Sussex

- **Beca BECAL** (Programa Don Carlos Antonio López) — cubre matrícula y manutención
- Restricción presupuestaria sustancialmente más holgada
- Permite dedicación completa a investigación

La beca BECAL no eliminó toda la incertidumbre, pero sí eliminó la restricción financiera como obstáculo principal.

Lección del modelo

El mismo individuo, la misma habilidad, el mismo destino — pero dos estructuras de financiamiento muy distintas con muy distinto margen de maniobra. **Las restricciones importan.**

Las dificultades reales

- **Distancia y soledad:** estar lejos de la familia tiene un costo emocional que no aparece en ninguna ecuación
- **Presión financiera constante:** incluso con beca y préstamo, los imprevistos existen — y el tipo de cambio también
- **Incertidumbre académica:** el doctorado implica años de trabajo sin saber si los resultados van a funcionar
- **Doble exigencia:** investigar y enseñar al mismo tiempo, en otro idioma, en otro sistema
- **El síndrome del impostor:** es real, y es más común de lo que se habla

Los retornos que no se anticipan

- **Red académica:** presentar en RES, LACEA, FU Berlin — contactos que se convierten en coautores, referentes, oportunidades
- **Capital no cognitivo:** autonomía, resiliencia, adaptabilidad — se acumulan en el proceso, no en el aula
- **Claridad sobre lo que querés:** a veces el mayor retorno es saber qué preguntas te importan
- **Valor de opción:** el doctorado abre puertas cuyo valor no se puede calcular cuando firmás la postulación

El modelo dice cuándo invertir. La experiencia te dice **cómo sostenerse** mientras la inversión madura.

Ya tenés las herramientas — ahora úsalas para vos

Todo lo que estudiamos hoy aplica a tu propia decisión:

- **Bonfiglioli et al.** muestran que las habilidades STEM y el capital humano de alta calidad son los únicos complementos de la IA $\Rightarrow$ la calidad de la institución importa
- **El paper de mismatch** muestra que el origen socioeconómico distorsiona la asignación — las becas son el correctivo más directo
- **El modelo de Becker** te dice que la pregunta no es “¿puedo costear estudiar afuera?” sino “¿cuál es el valor presente de hacerlo vs. no hacerlo?”

La ventaja que ya tienen

Ser economistas los pone un paso adelante: pueden **modelar su propia decisión**, identificar cuáles son sus restricciones reales vs. las percibidas, y entender cuándo una beca cambia el cálculo fundamentalmente.

La pregunta no es si vale la pena — es si están optimizando bajo las restricciones correctas.

Preguntas y Discusión 12:30 – 12:45

Hilo conductor del seminario

- I. La IA transforma el valor de las habilidades → el capital humano sigue importando, pero de formas distintas.
- II. El talento mal asignado implica pérdidas de bienestar y crecimiento potencial.
- III. La decisión de estudiar en el exterior puede analizarse rigurosamente con herramientas económicas.

`g.n.villalba-marecos@sussex.ac.uk`